Python para Análisis de datos: Introducción Sesión 1 Jesús Fernández (fernandez.cuesta@gmail.com) 1 Abril 2019 Introducción a Python Python es usado en Python como lenguaje de programación ¿? Instalación y entorno Entornos virtuales Conda Instalación Práctica I Práctica II **VSCODE**





Figure 1: Guido van Rossum, 1999

Definición y **evolución** del lenguaje recogido en PEPs (**Python Enhancement Proposals**)

- ► Énfasis en la productividad y legibilidad del código (PEP20)
 - Beautiful is better than ugly
 - Explicit is better than implicit
 - Simple is better than complex
 - Complex is better than complicated
 - Readability counts
 - **.**..
- +reusable, +fácil mantener

Ejemplo:

```
import math

num = input("Introduce un número [0, 1, 2, ...]: ")
num = int(num)  # convierte texto a número entero

print('El factorial de', num, 'es', math.factorial(num))

# de forma alternativa:

# print('El factorial de %s es %s' % (num, math.factorial(num)))

# print('El factorial de {} es {}'.format(num, math.factorial(num)))

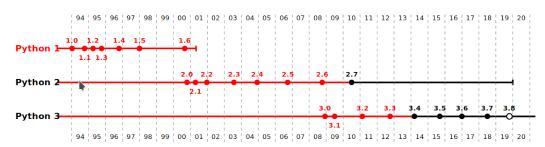
# print(f'El factorial de {num} es {math.factorial(num)}')
```

► Actualmente dos versiones principales activas:

```
Python 2.7 (soporte hasta 1/1/2020)
```

Python 3.x $(3.6, 3.7) \leftarrow$

```
python x.y.z
x: versión principal, incompatibles entre sí [2, 3]
y: versión secundaria, normalmente compatibles
z: versión menor (errores y seguridad)
$ python -V
Python 3.7.3
```



Línea temporal de versiones, en rojo: versión obsoleta

- Lenguaje de alto nivel, interpretado, orientado a objetos
- ► Alta productividad, no compilado
- ► Gran cantidad de librerías incorporadas (batteries included)
- ► + librerías externas (>1M): Python Package Index (PyPI)

Alto nivel

- Sencillo y comprensible
- Fácil de aprender
- Abstracción de datos
- Menos líneas de código
- Interfaces simples (pythonic)

```
>>> import requests
>>> r = requests.get('https://api.github.com/events')
>>> r.text
u'[{"repository":{"open_issues":0,"url":"https://github.com/...
```

```
Código ejemplo en C++
    #include <stdio.h>
    #include <stdlib.h>
    #include <unistd.h>
    #include <sys/types.h>
    #include <sys/socket.h>
    #include <netinet/in.h>
    #include <netdb.h>
    #include <arpa/inet.h>
    #include <err.h>
    char response[] = "HTTP/1.1 200 OK\r\n"
    "Content-Type: text/html; charset=UTF-8\r\n\r\n"
    "Hello, world!\r\n";
    int main()
      int one = 1, client_fd;
      struct sockaddr_in svr_addr, cli_addr;
      socklen_t sin_len = sizeof(cli_addr);
      int sock = socket(AF_INET, SOCK_STREAM, 0);
      if (sock < 0)
        err(1, "can't open socket");
      setsockopt(sock, SOL_SOCKET, SO_REUSEADDR, &one, sizeof(int));
      int port = 8080:
```

Equivalente python

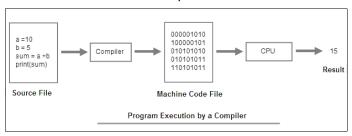
```
from flask import Flask
app = Flask(__name__)

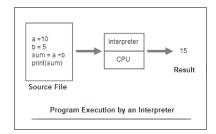
@app.route("/")
def hello():
    return "Hello World!"

Flask.run(app, port=8080)
```

Interpretado

▶ No es necesario compilar...





... pero necesitamos tener instalado un intérprete python.exe

Interpretado

- Compatible (en general) entre distintos sistemas operativos y arquitecturas:
 - Linux
 - MacOS
 - Windows
 - otros (AIX, AS/400, z/OS, OpenVMS, ARM, ...)
 - Arduino/Raspberry PI (IoT)
- Depuración de errores desde intérprete
- Gestión automática de memoria

Práctica

intérprete python

Anaconda Prompt > python (> ipython)

```
(base) C:\Users\IEUser>ipython
Python 3.7.0 (default, Aug 14 2018, 19:12:50) [MSC v.1900 32 bit (Intel)]
Type 'copyright', 'credits' or 'license' for more information
IPython 7.0.1 -- An enhanced Interactive Python. Type '?' for help.

In [1]: import datetime

In [2]: ahora = datetime.datetime.now()

In [3]: print(ahora)
2019-03-27 17:52:37.499641

In [4]: print(ahora.date())
2019-03-27

In [5]: print(ahora.time())
17:52:37.499641

In [6]: print(ahora + datetime.timedelta(days=-30))
2019-02-25 17:52:37.499641

In [7]:
```

Diferentes paradigmas de programación
Orientado a objetos
 Procedural Imperativo Funcional (<100%)
Python es usado en

Data Science



Machine Learning



Desarrollo Web

(p.e. pinterest, instagram, linkedin, ...)



Desarrollo software (scripts, prototipos, ...)

como "pegamento" entre componentes escritos en otros lenguajes





Automatización de procesos software



Automatización de procesos software

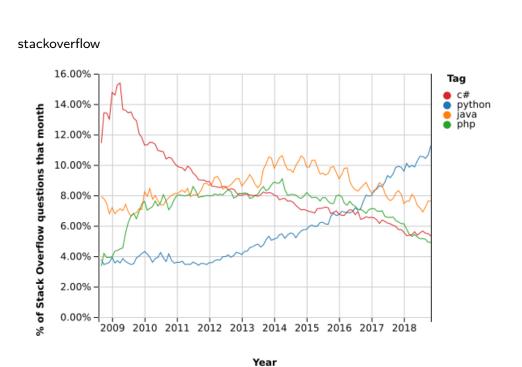


Python como lenguaje de programación

The 2018 Top Programming Languages, IEEE

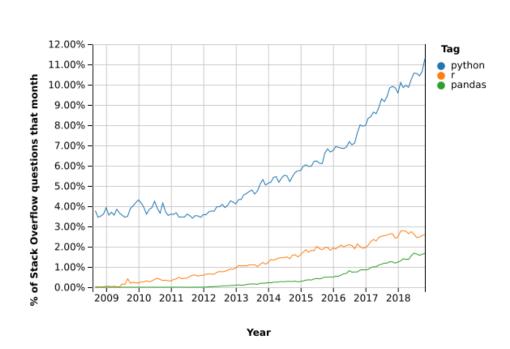
Language Rank	Types	Spectrum Ranking
1. Python	₩ 🖵	100.0
2. C++		99.7
3. Java		97.5
4. C	□ 🖵 🛢	96.7
5. C#		89.4
6. PHP		84.9
7. R	<u>_</u>	82.9
8. JavaScript		82.6
9. Go	₩ 🖵	76.4
10. Assembly		74.1

gran soporte en foros, comunidades, conferencias, ...



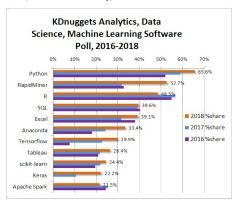
Worldwide, Python is the most popular language, Python grew the most in the last 5 years (PYPL)





fuente: stackoverflow

- R: muy enfocado en análisis estadístico
- Python: generalista, con librerías especializadas (pandas, scikit-learn, scipy, ...)
- ► Encuesta 2017
- Encuesta 2018
- Python Data Science



?3



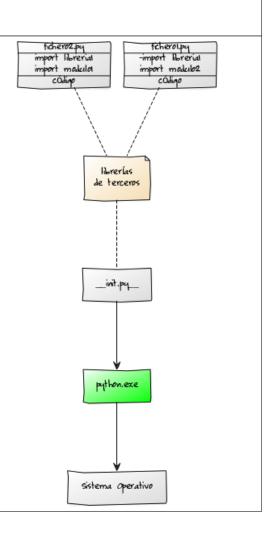
Figure 2: Guido van Rossum, 1995

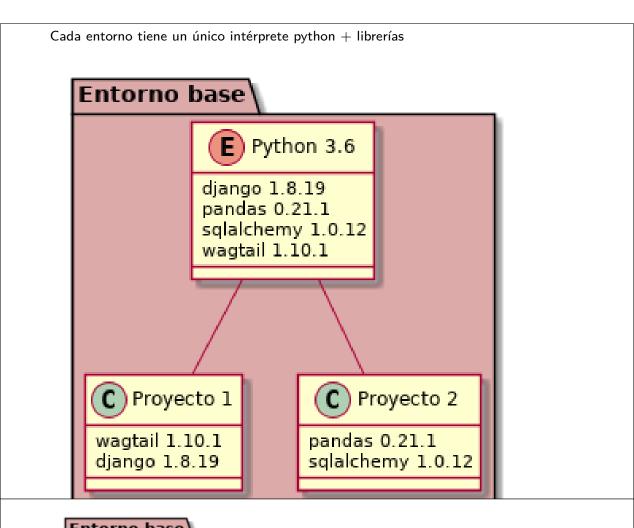
ı	Instalación y entorno
Diferentes distribuciones para \(\) python (cpython) conda (anaconda/minicon) canopy winpython enfocado a sitemas Win no necesita ser instalado incluye compilador C/C cativepython (comercial)	nda) adows

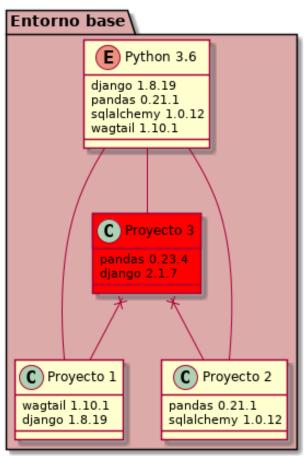
Podemos ejecutar código python:

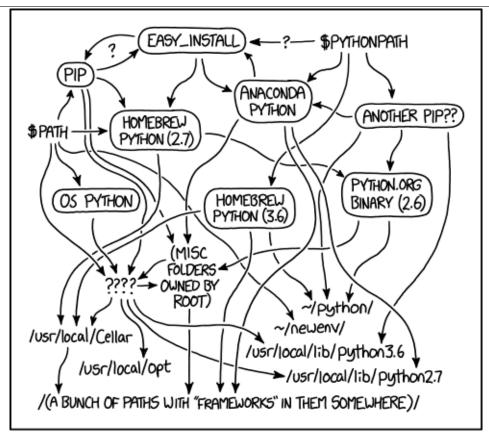
- Directamente (si el S.O. lo permite, #!)
- Desde un intérprete interactivo python (p.e. ipython, bpython)
- Desde un cuaderno jupyter

- Para ejecutar código python necesitaremos un intérprete (python.exe).
- Preinstalado en ciertos S.O. (p.e. Linux, Mac OS X)
- ▶ Diferentes tipos de intérprete (CPython, PyPy, Jython, IronPython...)
- Podemos tener "n" intérpretes distintos instalados en el sistema, cada uno con diferentes librerías
- conda: instala por defecto un entorno (intérprete) base y un conjunto de librerías



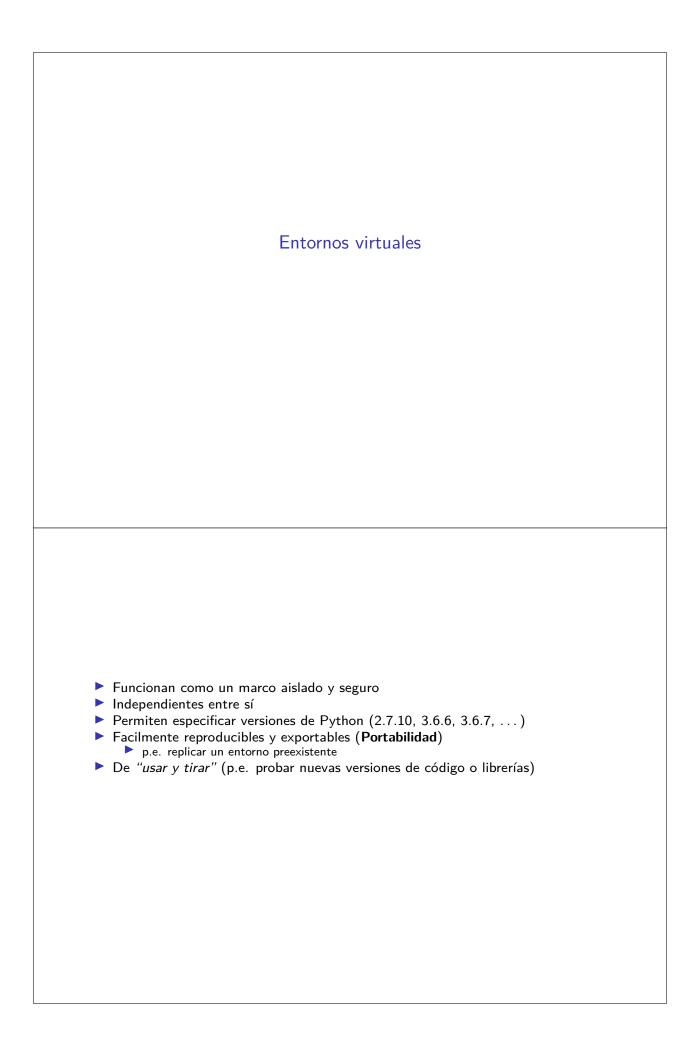






MY PYTHON ENVIRONMENT HAS BECOME SO DEGRADED THAT MY LAPTOP HAS BEEN DECLARED A SUPERFUND SITE.

¿Solución?



Entorno base

Python 3.6

django 1.8.19
pandas 0.21.1
sqlalchemy 1.0.12
wagtail 1.10.1

C Proyecto 1

C Proyecto 2

pandas 0.21.1

sqlalchemy 1.0.12

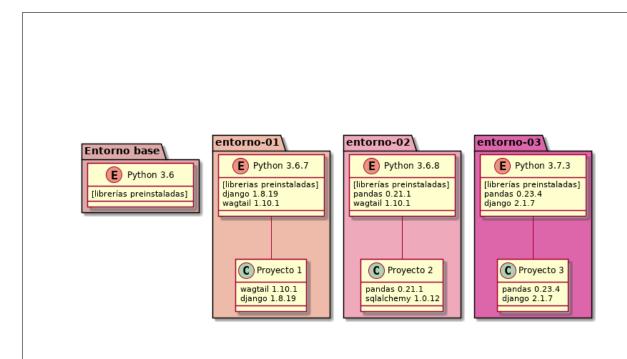
Regla general: evitar usar el intérprete global del sistema y el entorno base

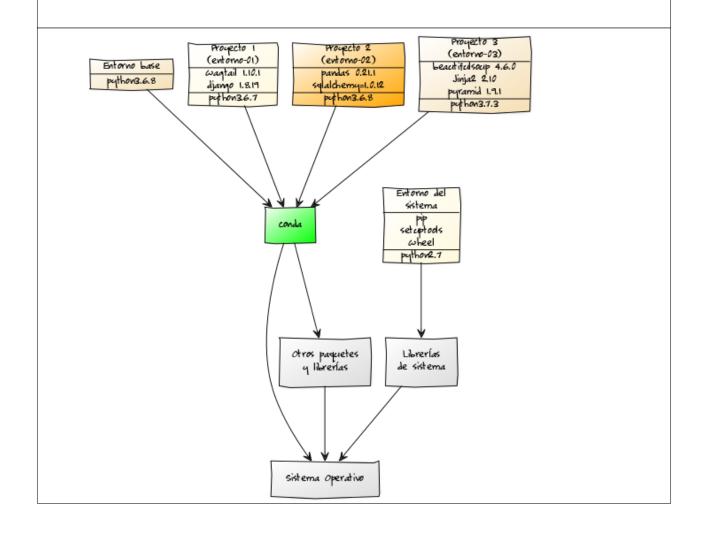
► Puede afectar a otros componentes

wagtail 1.10.1

django 1.8.19

- Dependencias entre distintos proyectos
- Puede no ser la misma versión que la requerida en un proyecto





Conda	
Conda (anaconda/miniconda) Gestor de paquetes multi-lenguaje (python/R/) Transparente: no instala ficheros fuera de su directorio Distribución multipropósito, gestiona paquetes adicionales (p.e. git, librerías,) Coexistencia de entornos con diferentes librerías y versiones de python Por defecto nos encontraremos en un entorno llamado base	

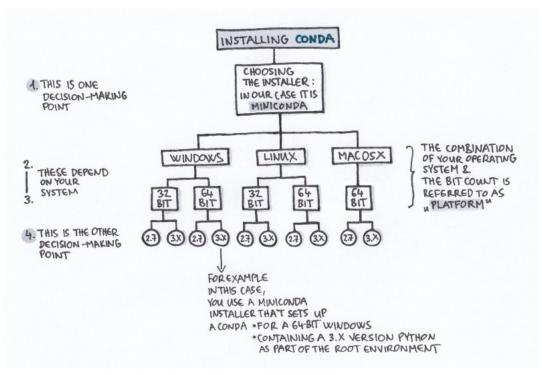
Anaconda	Miniconda
~3GB disco	<400MB
> 200 librerías	base + dependencias
+ herramientas	ciclo distribución +rápido
IDE (Spyder + VSCode)	
Anaconda Navigator	sin interfaz gráfico
↑ tiempo instalación	

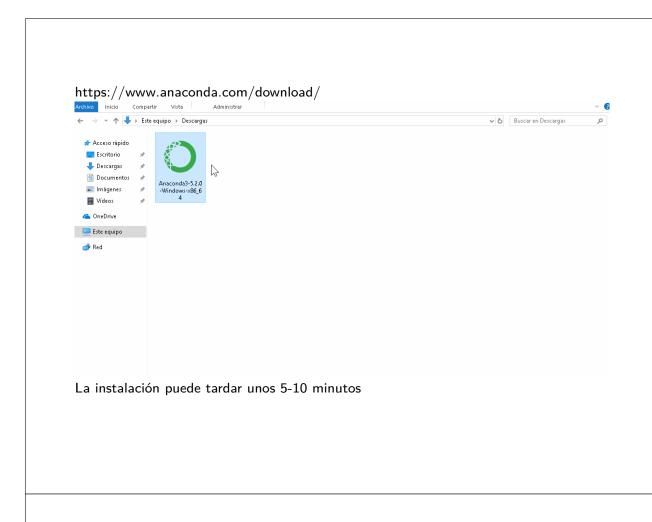
Alternativas (más bajo nivel):

- python + pipenvpython + virtualenvwrapper (lazy)

Instalación

Determinar la plataforma sobre la que se va a instalar

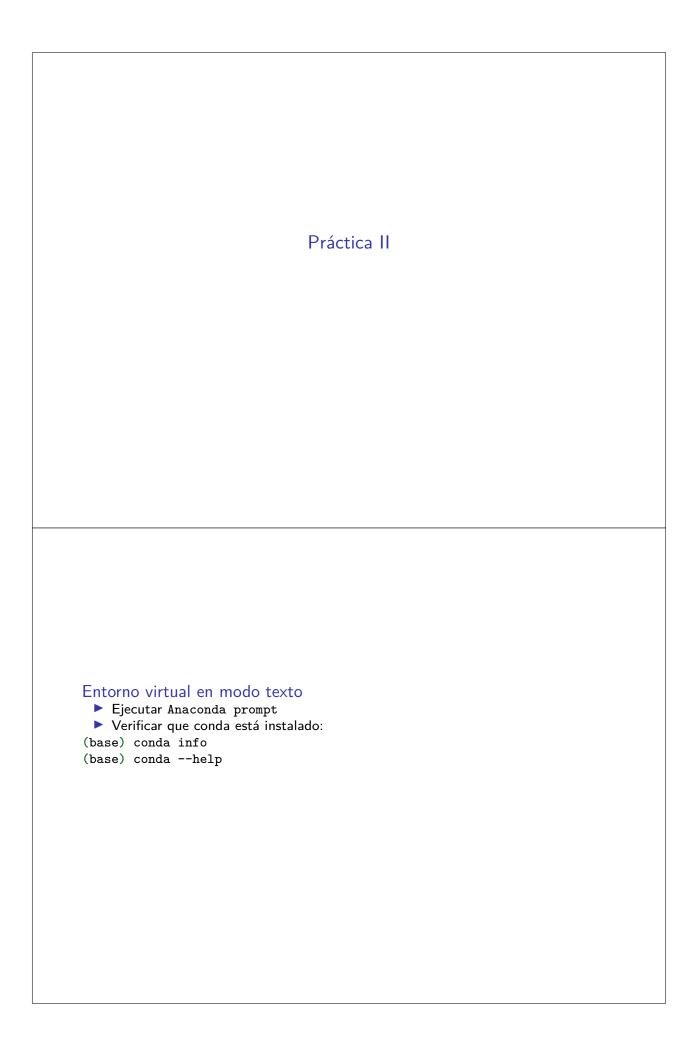




Práctica I

diferences indicates in	staladas, p.e.: pandas	bs4) con
	matplotlib scrapy sqlalchemy jsonschema	jupyter scipy flask bokeh	

Г



Crear un entorno virtual con pandas, matplotlib, jupyter y pyjstat.

► Inicializar el entorno virtual:

```
(base) conda create --name entorno-01
(base) conda create --name entorno-02 python=2.7 --yes
# crea entorno con paquetes preinstalados
(base) conda create -n entorno-03 python=3.7 pandas scipy -y
```

► Acceder (activar) el entorno virtual:

```
(base) conda activate entorno-03
(entorno-03) conda list # muestra paquetes instalados
```

Crear un entorno virtual con pandas, matplotlib, jupyter y pyjstat.

Instalar librerías adicionales dentro del entorno

```
# instala librerías gestionadas por conda
(entorno 03) conda install matplotlib jupyter --yes
# instala paquetes no gestionados por conda desde PyPI (Python Package Index)
(entorno-03) pip install -y pyjstat
```

Exportar entorno virtual

```
# exportar definición del entorno
(entorno-03) conda list --export > requirements.txt # solo dependencias
(entorno-03) conda env export > entorno-03.yml # entorno + dependencias
```

Distribuible y replicable

► Acceder al entorno virtual y mostrar librerías instaladas

(base) conda activate entorno-03

(entorno-03) conda list # muestra paquetes instalados

instala paquetes adicionales
(entorno-03) conda install jupyter -y

instala paquetes desde PyPI, no gestionados por conda
(entorno-03) pip install pyjstat
(entorno-03) conda list

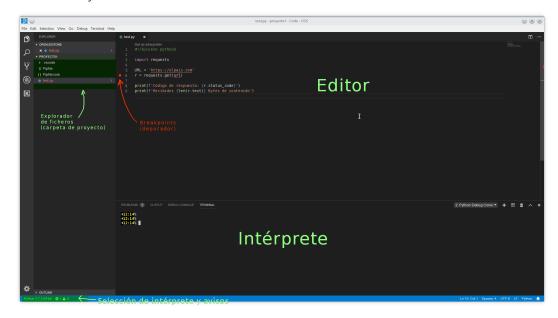
instala paquetes desde github usando pip
(entorno-03) pip install -e ^

"git+https://github.com/predicador37/pyjstat.git#egg=pyjstat-git"

- ► Resumen comandos conda
- ► Guía de usuario pip

VSCODE

- Paleta de comandos (Ctrl+Shift+P)
 "Instalar extensiones"
 "Python: ..."



Integración con el entorno virtual de cada proyecto

- ► Seleccionar intérprete + nombre del entorno
- terminal > ipython / python o bien "Python: ejecutar REPL"

Linter
 Analizador del código, detecta errores de sintaxis, estilo, Necesario instalar en cada entorno (preinstalado en base) Paleta de comandos > Python: seleccionar Linter > flake8
flake8
 Comprueba conformidad con PEP8, complejidad de McCabe, errores de sintaxis Permite ignorar/silenciar diferentes avisos, excluir ficheros del análisis,

Depuración de errores

- ► Errores de sintaxis
- Avisos del linter

```
#!/bin/env python3
import requests

URL='https://elpais.com'
r = requests.get(url) # crear un breakpoint aquí

print(f'Código de respuesta: {r.status_code}')
print(f'Recibidos {len(r.text)} Bytes de contenido')
```

Estructura del código

- No hay delimitadores de línea (tipo ';')
- ► Comentar código con #
- ▶ Jerarquía del código según nivel de indentación
- Indentar código con espacios
- Importar librerías al inicio
- Código agrupado con líneas en blanco

► No hay delimitadores de línea (tipo ;)

▶ **Recomendado**: Longitud de línea < 80 caracteres

```
▶ Jerarquía del código según nivel de sangría (indent)
▶ Diferenciarlo con espacios ¹
import os

home = os.path.expanduser('~') # directorio del usuario
directorio_entorno = os.path.join(
    home, 'Anaconda3', 'envs', 'entorno-03'
)
ficheros = []

# Busca ficheros y guarda (nombre, tamaño)
for f in os.listdir(directorio_entorno):
    if os.path.isfile(f):
        tamaño = os.stat(os.join(directorio_entorno), f).st_size
        ficheros.append((f, tamaño))
    print(f)
print(tamaño)
¹ Generalmente con 4 espacios, no mezclar con TAB
```

- Importar librerías al inicio
- Código agrupado con líneas en blanco

```
Palabras reservadas
import builtins
import keyword
print(', '.join(keyword.kwlist))
False, None, True, and, as, assert, async, await, break, class,
continue, def, del, elif, else, except, finally, for, from,
global, if, import, in, is, lambda, nonlocal, not, or, pass,
raise, return, try, while, with, yield
print(dir(builtins))
['ArithmeticError', 'AssertionError', 'AttributeError', 'BaseException',
'BlockingIOError', 'BrokenPipeError', 'BufferError', 'BytesWarning',
'ChildProcessError', 'ConnectionAbortedError', 'ConnectionError',
'ConnectionRefusedError', 'ConnectionResetError', 'DeprecationWarning',
'EOFError', 'Ellipsis', 'EnvironmentError', 'Exception', 'False',
'FileExistsError', 'FileNotFoundError', 'FloatingPointError', 'FutureWarning',
'GeneratorExit', 'IOError', 'ImportError', 'ImportWarning', 'IndentationError',
'IndexError', 'InterruptedError', 'IsADirectoryError', 'KeyError',
'KeyboardInterrupt', 'LookupError', 'MemoryError', 'ModuleNotFoundError',
'NameError', 'None', 'NotADirectoryError', 'NotImplemented',
'NotImplementedError', 'OSError', 'OverflowError', 'PendingDeprecationWarning',
'PermissionError', 'ProcessLookupError', 'RecursionError', 'ReferenceError',
'ResourceWarning', 'RuntimeError', 'RuntimeWarning', 'StopAsyncIteration',
'StopIteration', 'SyntaxError', 'SyntaxWarning', 'SystemError', 'SystemExit',
'TabError', 'TimeoutError', 'True', 'TypeError', 'UnboundLocalError',
'UnicodeDecodeError', 'UnicodeError', 'UnicodeError',
if __name__ == "__main__":
Se llama a __main__() cuando se ejecuta directamente:
(base) python circumferencia.py
import sys
import math
def area(radio):
   return math.pi * (radio ** 2)
def longitud(radio):
    return 2 * math.pi * radio
# entra aquí cuando se ejecuta directamente
if __name__ == "__main__":
    radio = float(sys.argv[1]) # sys.arqv[] son los arqumentos de entrada
   print(
        "La longitud de una circunferencia de radio {}cm es {:.2f}cm^2."
        .format(radio, longitud(radio))
   print("El area de una circunferencia de radio {1}cm es {0:.2f}cm^2."
          .format(area(radio), radio))
```

- ▶ Un fichero python puede contener (entre otros) definiciones de constantes, variables, funciones o clases.
- Para organizar el código guardaremos los ficheros .py en un árbol de directorios:

```
principal/
    __init__.py
    practica.py
    recolector/
        __init__.py
        collector.py
        database.py
    conversor/
        __init__.py
        limpia.py
        procesa.py
    graficos/
        __init__.py
        graficos.py
        exportar.py
    string/
        __init__.py
        string.py
```

Proyecto ejemplo

```
nombre del paquete
proyecto/
                                   descripción del proyecto
    README.rst
    LICENSE
                                   licencia
                                   distribución/empaquetado [2]
    setup.py
                                   descripción de las dependencias
    requirements.txt
                                   descripción del entorno
    entorno_conda.yml
                                   el código en sí
    ejemplo/__init__.py
                                   11 11
    ejemplo/core.py
                                   11 11
    ejemplo/helpers.py
                                   documentación del proyecto
    docs/conf.py
    docs/index.rst
                                   funciones de test del proyecto
    tests/unitarios.py
    tests/funcionales.py
  <sup>2</sup> p.e. setuptools
```

Práctica III
Parte 1 Abrir una consola ipython In[n] identifica las entradas de comandos comandos mágicos (solamente para ipython) comienzan por el caracter "%" ejemplo: %edit, %pylab Ctrl+R activa la búsqueda en el historial %hist, %history para visualizarlo guarda la salida del último comando 3 se usa también como variable de usar/tirar, p.e. cuando una función devuelve varios resultados, pero solamente estamos interesados en uno.

► [TAB] autocompleta (p.e. import st[TAB]) muy util para ver los métodos/atributos de un módulo/clase

In[]: import st[TAB] In[]: import string

In[]: string.[TAB]

string.Formatter string.ascii_uppercase string.octdigits string.Template string.capwords string.printable string.ascii_letters string.digits string.punctuation string.ascii_lowercase string.hexdigits string.whitespace

In[1]: ? # muestra ayuda del intérprete ipython In[2]: ? dict # muestra ayuda breve de un método/clase/... In[3]: help(dict) # muestra ayuda completa In[4]: import math In[5]: math.sq[TAB]

In[5]: math.sqrt(94)

In[6]: a = _ # recupera última salida

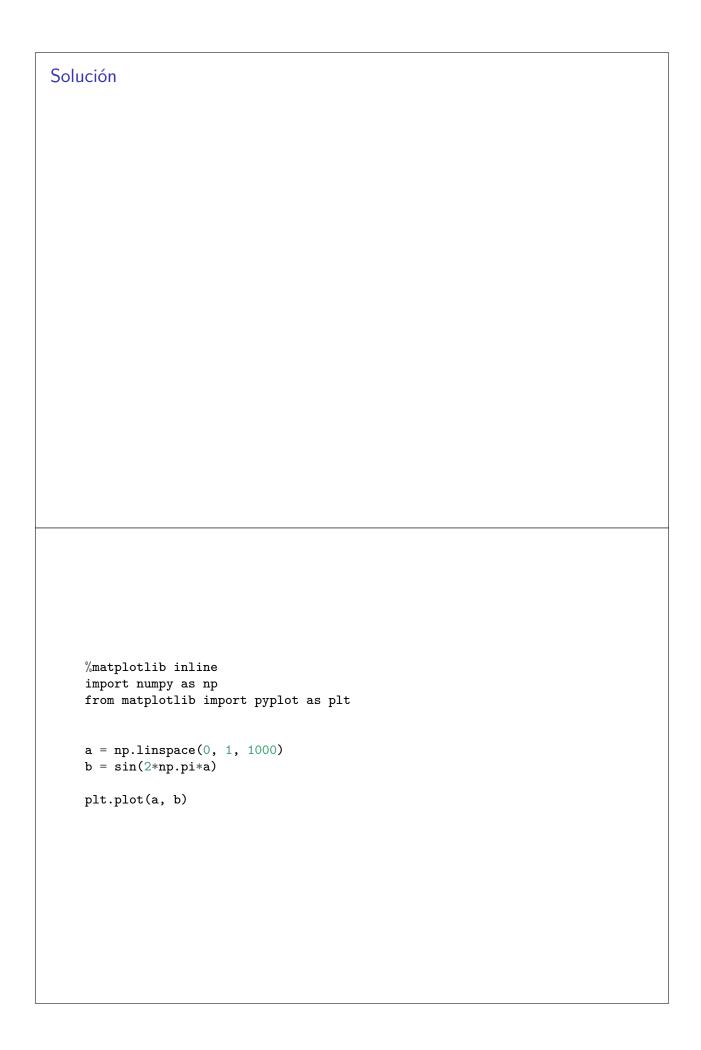
In[7]: dir(math) # muestra todos los métodos

 Importa la librería math Convierte 67 grados a radianes (math.radians) Calcula la raíz cúbica del resultado (math.pow) Verifica si el resultado es mayor que 14/13 	
Solución	

```
import math
grados = math.radians(67)
math.pow(grados, 1/3) > 14/13
False
```

Parte 2

- ► Importa el módulo numpy ► import numpy as np
- Crea un array a de 1000 puntos entre [0, 1]
 Ejecuta el método np.linspace
- Calcula el seno de $2 \cdot \pi \cdot a$
 - Usa la constante np.pi
- ► Activa el modo gráfico integrado ► %matplotlib inline
- ► Crea el gráfico de (a, seno(a))



Práctica IV	
Abrir el cuaderno de ejemplo y ejecutar línea por línea.	
cuaderno ejemplo offline	

Práctica V

Exportar entorno virtual

```
# exportar definición del entorno

# solo dependencias
(entorno-01) conda list --export > requirements.txt

# entorno + dependencias
(entorno-01) conda env export > entorno-01.yml

# Desde otro sistema, restaurar el entorno
(base) conda env create -f entorno-01.yml

# O bien el la misma máquina, con otro nombre:
(entorno-01) conda list --export > requirements.txt
(entorno-01) deactivate
(base) conda env create --name entorno-11 --file requirements.txt
(base) activate entorno-11
(entoro-11) conda list
```

▶ Restaurar solo dependencias (requirements.txt): independiente de conda

Recursos adicionales
 Guías de estilo: PEP8 Guía de estilo de Google Cuadernos Jupyter para Data Science

Otros recursos en línea Librería standard de Python Guía de referencia de Python Guía para principiantes The Hitchhiker's Guide to Python! Stackoverflow Stackoverflow en español awesome python	
Bonus: [pipenv]	

Permite gestionar un entorno virtual y sus dependencias ::: .dummy ► Instalación desde pip Cada carpeta de proyecto es considerada un entorno virtual Pipfile y Pipfile.lock definen las dependencias
 Pipfile.lock para versiones específicas, evitando que se actualicen
 Recomendable añadir ambos ficheros en control de versiones ▶ Ejecutar scripts con pipenv run ... ::: Instala [pipenv] y crea un entorno virtual nuevo \$ mkdir proyecto \$ cd proyecto \$ pipenv --python=3.7 [--three]

Instala distintos paquetes dentro del entorno virtual

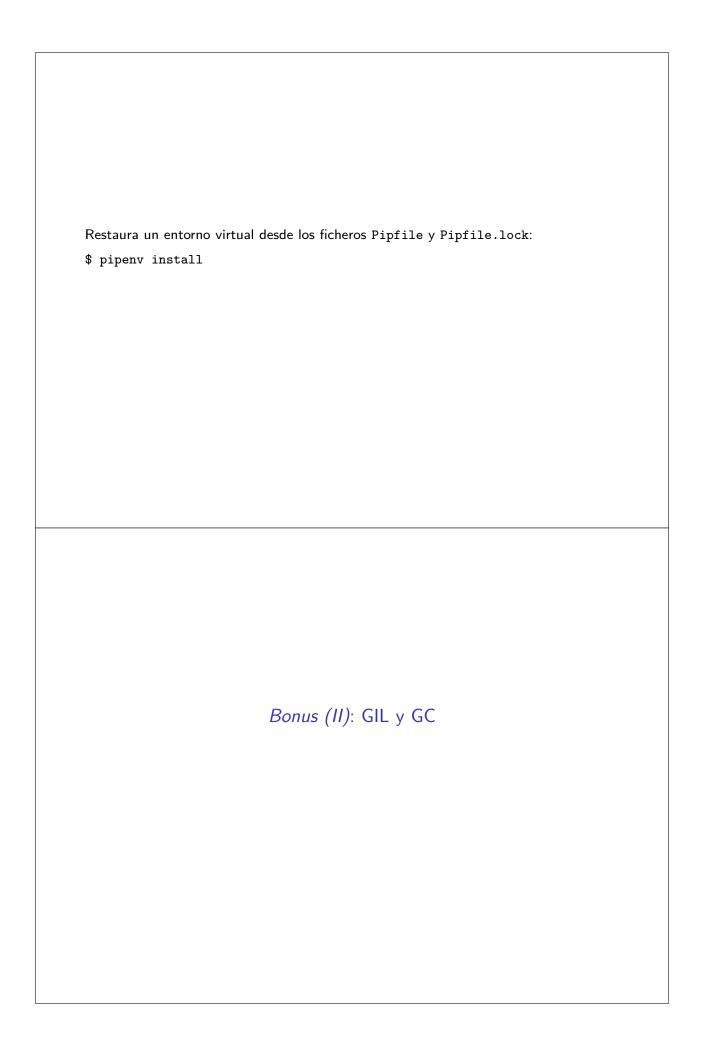
```
$ pipenv install bpython
$ pip install 'pandas==' # muestra versiones disponibles [0J0! pip]
$ pipenv install 'pandas==0.23.1' 'requests==2.2.1'
$ pipenv install 'lxml==3.*' # bloquea solamente la rama 3.x
$ pipenv install 'untangle==1.1.*' # bloquea versiones [major, minor]
$ pipenv install -r requirements.txt # instala desde un fichero requirements
$ pipenv lock -r > requirements.txt # exporta a fichero requirements
```

Para comprobar los paquetes instalados, mostrar el contenido de Pipfile

```
$ cat Pipfile
$ cat Pipfile.lock
```

```
Otras funcionalidades útiles con pipenv:
# muestra dónde instala realmente el entorno
$ pipenv --venv
# muestra gráfico de dependencias
$ pipenv graph
# muestra vulnerabilidades con los paquetes instalados
$ pipenv check
Acceder al intérprete propio del entorno:
$ pipenv shell
$ python # o bpython/ipython si está instalado
# o bien: pipenv run python
```

```
Ejecutar código cargando librerías propias del entorno:
>>> import pandas as pd
>>> URL_crypto = 'https://api.coinmarketcap.com/v1/ticker/'
>>> cc = pd.read_json(URL)
>>> cc.set_index('id', inplace=True)
>>> cc[cc['price_usd'] < 300.0]
# desinstala todos los paquetes no especificados en `Pipfile.lock`
$ pipenv clean
# destruye el entorno virtual
$ pipenv --rm
```



Reference counting

- Usado por python para la gestión de memoria
- ► Cuenta las referencias a cada objeto creado
- Cuando la cuenta es 0, la memoria reservada se libera

```
import sys
```

```
a = []
b = a
sys.getrefcount(a)
3
```

GC: Garbage Collector

Utiliza 2 algoritmos para la gestión de memoria:

- Reference counting: libera objetos sin referencias en un programa
 ejecutado en "tiempo real"
- ► Referencias cíclicas: se ejecuta periódicamente

Ejemplo

```
foo = []

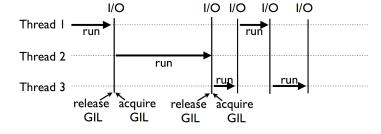
# 2 referencias, 1 de la variable foo y una de la llamada a getrefcount
print(sys.getrefcount(foo))

def bar(a):
    # 4 referencias
    # variable foo, argumento a función, getrefcount + pila interna de python
    print(sys.getrefcount(a))

bar(foo)
# 2 referencias, se limpiaron las propias de la función
print(sys.getrefcount(foo))
```

GIL: Global Interpreter Lock

- ► Afecta a CPython
- Evita que la variable de conteo de referencias entre en condición de carrera
- ► Restringe la ejecución de código concurrente
 - ejecución secuencial dentro del intérprete
 - multithreading: aplicaciones no limitadas por CPU (p.e. I/O)
 - multiprocessing: varios intérpretes concurrentemente



Ejemplo práctico: programa limitado por CPU, ejecución secuencial

```
# single_threaded.py
import time

COUNT = 50000000

def countdown(n):
    while n>0:
        n -= 1

start = time.time()
countdown(COUNT)
end = time.time()

print('Tiempo de ejecución {:.2f} segundos'.format(end - start))
$ python single_threaded.py
Tiempo de ejecución 2.30 segundos
```

Programa limitado por CPU, ejecución concurrente (multithread)

```
# multi_threaded.py
import time
from threading import Thread
COUNT = 50000000
def countdown(n):
    while n>0:
        n = 1
thread_1 = Thread(target=countdown, args=(COUNT//2,))
thread_2 = Thread(target=countdown, args=(COUNT//2,))
start = time.time()
thread_1.start()
thread_2.start()
thread_1.join()
thread_2.join()
end = time.time()
print('Tiempo de ejecución {:.2f} segundos'.format(end - start))
$ python multi_threaded.py
Tiempo de ejecución 2.85 segundos
```

Programa limitado por CPU, ejecución concurrente (multiprocess)

```
# multi_process.py
import time
from multiprocessing import Pool

COUNT = 50000000

def countdown(n):
    while n>0:
        n -= 1

start = time.time()
with Pool(2) as p: # bypass del GIL
    p.map(countdown, 2* [COUNT//2])
end = time.time()

print('Tiempo de ejecución {:.2f} segundos'.format(end - start))
$ python multi_threaded.py
Tiempo de ejecución 1.32 segundos
```

cuaderno jupyter (offline) cuaderno jupyter